

# La misma voz para lo cierto y lo inventado

---

*Anatomía de una conversación real con una IA avanzada, y de las cuatro rectificaciones que solo se produjeron porque alguien preguntó.*

Una inteligencia artificial no cambia de registro cuando pasa de lo comprobado a lo inventado. Escribe igual de bien en ambos casos: mismas ecuaciones, mismos nombres de teoremas, misma cadencia serena. Este documento no lo explica en abstracto: **lo enseña**. Reproduce cuatro afirmaciones falsas o mal fundadas producidas en una conversación técnica real, las rectificaciones que las siguieron, y qué le habría ocurrido a un lector que hubiera aceptado la primera versión sin revisarla. Después extrae las técnicas de interacción que hicieron aflorar los fallos — y para qué sirve todo esto: obtener de la IA su valor real.

---

**Diálogo original:** agosto de 2026 · conversación sobre relatividad general

**Dirección editorial, objeciones y criterio:** EIGL

**Redacción:** Claude Fable 5 (Anthropic) · véase la nota de procedencia al final

# Índice

---

|                                                        |    |
|--------------------------------------------------------|----|
| 1. Advertencia sobre este mismo documento .....        | 3  |
| 2. El hecho central .....                              | 3  |
| 3. Los cuatro casos .....                              | 5  |
| 3.1 De ecuación correcta a conclusión falsa .....      | 6  |
| 3.2 Rechazar la pregunta en lugar de responderla ..... | 7  |
| 3.3 Conclusión correcta, criterio equivocado .....     | 8  |
| 3.4 El error que no es una afirmación .....            | 9  |
| 4. El residuo: lo que nadie detectó .....              | 10 |
| 5. Verificación posterior de tres afirmaciones .....   | 11 |
| 6. Catálogo de dispositivos de convicción .....        | 12 |
| 7. Nueve técnicas y el ciclo completo .....            | 13 |
| 8. Ficha de bolsillo .....                             | 15 |
| 9. Glosario mínimo .....                               | 15 |
| 10. Nota de autoría y procedencia .....                | 16 |

## Cómo leer este documento

No hace falta entender relatividad general. La física es el *escenario*; el objeto de estudio es cómo se comporta el texto generado. Cada caso puede seguirse sin conocimientos previos: se muestra lo que la IA escribió, por qué resulta convincente, qué fallaba, qué frase lo sustituyó, y —en una franja diferenciada— qué le habría ocurrido a un lector que lo hubiera aceptado tal cual.

Si dispone de poco tiempo, lea las secciones **2**, **7** y **8**. Si quiere el argumento completo, léalo entero: la fuerza del documento está en ver los cuatro casos seguidos y comprobar que ninguno se distingue de los pasajes correctos que los rodean.

## De dónde sale este material

La conversación analizada ocupó ocho turnos y trató sobre relatividad general: si la gravedad es una fuerza, qué queda de la geometría al retirar la materia, si la energía se conserva, si el vacío puede tener energía nula, si pueden surgir ondas gravitatorias espontáneamente. Terreno técnico, bien establecido y con literatura abundante contra la que verificar.

En tres de los cuatro casos, el usuario no necesitó refutar con conocimiento especializado. Hizo algo más reproducible: **tomó una frase de la respuesta y pidió que se enunciara en su versión fuerte** —«cuando dices X, ¿afirmas que Y en ninguna circunstancia?»—. No refutó: obligó a explicitar el alcance, y las afirmaciones que no lo resistían se cayeron solas. Esa técnica no requiere ser físico; requiere leer con atención. El cuarto caso —una presuposición escondida en una sola palabra— exigió algo más, y por eso se analiza como el límite de la técnica. Los pasajes citados en la sección 3 son literales, tanto los generados como las rectificaciones.

## Advertencia sobre este mismo documento

---

### LÉASE ANTES QUE NADA

Este documento lo ha generado el mismo sistema cuyos fallos analiza, por el mismo procedimiento y con dos salvaguardas añadidas: la verificación parcial contra fuentes externas que documenta la sección 5, y la auditoría de un editor humano que ha cuestionado y exigido cada edición. La IA no dispone de acceso privilegiado a cuáles de sus afirmaciones son verdaderas: puede señalar los errores que *ahora* reconoce como errores, no los que sigue teniendo por correctos. Toda autoauditoría de una IA tiene ese techo, y este texto lo tiene.

Y una segunda advertencia, más importante que la primera: **que un texto sea autocrítico no lo hace más fiable**. La autocrítica fluida es un producto tan generable como la afirmación errónea, y funciona mejor porque desarma. Si al terminar de leer confía usted más en la IA que al empezar, el documento habrá producido exactamente el efecto contrario al que busca.

Esta advertencia no es una fórmula de modestia: es la condición de lectura. Un análisis de la falibilidad de una máquina, escrito por esa máquina, tiene el mismo estatus epistémico que cualquier otra cosa que produzca: hay que verificarlo. Las afirmaciones de este documento comprobadas contra fuentes externas están marcadas como tales en la sección 5. Las demás, no lo están, y son mayoría.

Este documento ha pasado además por una revisión posterior a su primera versión, y algunas de las correcciones que esa revisión produjo se dejan visibles en el propio texto, en notas al margen como la que encontrará en la sección siguiente. No se han borrado porque son la mejor demostración disponible de la tesis: **los errores que se muestran aquí sobrevivieron a un primer texto cuidado, bien escrito, y dedicado precisamente a advertir sobre errores**.

---

### SECCIÓN 2

## El hecho central

---

En una misma conversación técnica, una IA avanzada produjo afirmaciones exactas y afirmaciones inexactas con idéntico registro: mismas ecuaciones bien escritas, mismos nombres de teoremas reales, misma estructura de párrafo, misma cadencia de «*y ahora la parte incómoda*». Nada en la superficie del texto separaba unas de otras.

Conviene enunciar la consecuencia con precisión, porque es fácil enunciarla mal: **la seguridad con que una IA se expresa no es un indicador en el que el lector pueda apoyarse**. El tono técnico, la ausencia de titubeo y la sensación de solidez aparecen por igual cuando el contenido es correcto y cuando no lo es. Leerlos como señal de exactitud es leer una señal que no discrimina. La fluidez es constante; la exactitud varía.

#### CORRECCIÓN DEJADA A LA VISTA

La primera versión de este documento afirmaba aquí que la seguridad expresiva «no está correlacionada con la verdad». Eso es un sobreennunciado del mismo tipo que el documento denuncia: afirma una correlación exactamente nula, cosa que nadie ha medido así y que probablemente sea falsa en sentido estricto. La formulación defendible es la de arriba: la relación es demasiado débil e inestable para servirle de guía al lector. La frase fuerte sonaba mejor. Por eso estaba ahí.

¿Por qué ocurre? En primera aproximación: el tono de un texto generado no se produce a partir de un estado interno de certeza, sino a partir del registro que corresponde al tipo de texto que se está escribiendo. Un texto técnico suena técnico tanto si su contenido es correcto como si no. Algunos sistemas pueden expresar incertidumbre cuando se les pide explícitamente; lo que no hacen de forma fiable es marcarla por defecto, frase a frase, donde el lector la necesitaría.

En un ser humano el registro cambia —imperfectamente, pero cambia— con la confianza: quien está seguro afirma; quien duda titubea, matiza, dice «creo recordar». Esa correlación —también falible: hay personas que afirman con aplomo lo que ignoran— es la que usamos a diario para calibrar a nuestros interlocutores, y la trasladamos sin querer a la máquina. Es un error de transferencia, y la figura siguiente lo resume mejor que cualquier párrafo.



**Figura 1.** Dos pasajes de la misma conversación, vistos como los ve el lector: misma extensión, misma estructura, misma ecuación destacada en el mismo lugar. Uno era exacto; el otro, confabulado. La superficie del texto no dice cuál es cuál — y, dentro de la conversación, la superficie del texto es todo lo que el lector tiene. Lo que discrimina está fuera: la verificación. Por eso importa tanto.

#### DATO DURO DE ESTE CASO

Las cuatro rectificaciones que documenta la sección 3 **fueron todas provocadas por el usuario**. Ninguna se produjo espontáneamente. La capacidad de autocorrección existe y funciona, pero es *reactiva*: sin un interlocutor que empuje, los errores permanecen y sirven de base a lo que viene después.

## Los cuatro casos

Cada caso sigue el mismo esquema: el texto tal como se generó, por qué resulta difícil no creerlo, qué fallaba en realidad, la rectificación literal posterior, una tabla que aísla qué cambió, y una franja final —con borde discontinuo— que responde a la pregunta que de verdad importa: **¿qué le habría pasado a un lector que lo hubiera aceptado tal cual?**

Los cuatro casos son de naturaleza distinta, y esa variedad es el punto: no hay un único modo de fallar, y cada modo burla un tipo distinto de comprobación. La tabla siguiente los resume; las páginas que siguen los desarrollan uno por uno.

| CASO                                           | TIPO DE FALLO                                           | POR QUÉ LA COMPROBACIÓN HABITUAL NO LO CAZA                                                                    |
|------------------------------------------------|---------------------------------------------------------|----------------------------------------------------------------------------------------------------------------|
| 3.1 — De ecuación correcta a conclusión falsa  | Inferencia inválida sobre una premisa verdadera.        | Verificar el dato no verifica el «por lo tanto». El dato sale correcto y el párrafo entero hereda el aprobado. |
| 3.2 — Rechazar la pregunta                     | Descalificación del interlocutor en lugar de respuesta. | No hay nada que comprobar: es un veredicto, no un dato. El daño es que la pregunta legítima se abandona.       |
| 3.3 — Conclusión correcta, criterio equivocado | Resultado exacto explicado por la razón errónea.        | Verificar el resultado lo <i>confirma</i> , y la confirmación sella el error dentro.                           |
| 3.4 — El error que no es una afirmación        | Presuposición encubierta en una palabra.                | La afirmación explícita es verdadera; lo indebido viaja en la sintaxis, donde nadie mira.                      |

### Código visual de los casos

|                                                                                                                                         |
|-----------------------------------------------------------------------------------------------------------------------------------------|
| TEXTO GENERADO                                                                                                                          |
| Barra azul: lo que la IA escribió en primera instancia, citado literalmente.                                                            |
| RECTIFICACIÓN POSTERIOR                                                                                                                 |
| Barra verde: lo que la IA escribió tras la objeción del usuario, también literal.                                                       |
| SI SE HUBIERA ACEPTADO TAL CUAL                                                                                                         |
| Barra roja discontinua: el escenario contrafactual, lo único de cada caso que <i>no</i> ocurrió — precisamente porque alguien preguntó. |

Una observación transversal antes de entrar: los cuatro fallos convivían con pasajes correctos, extensos y valiosos. El problema práctico de una IA no es que falle mucho —en esta conversación acertó mucho más de lo que falló—, sino que **falla indistinguiblemente**: el error no viene marcado, viene bien escrito.

### 3.1 De ecuación correcta a conclusión falsa

#### TEXTO GENERADO

«Las identidades de Bianchi implican  $\nabla_\mu T^{\mu\nu} = 0$  como consecuencia *estructural* de las ecuaciones de Einstein. La masa-energía no puede desaparecer: solo trasladarse o convertirse. No es una prohibición añadida, es que la geometría misma impone la conservación.»

#### POR QUÉ ES DIFÍCIL NO CREERLO

La ecuación es correcta. La identidad de Bianchi existe y dice lo que se dice que dice. Y la frase final ofrece al lector la sensación de que se le está mostrando una estructura profunda: «*no es una prohibición añadida, es que...*». Ese giro presenta la conclusión como más fundamental de lo que el lector esperaba. El lector siente que ha entendido algo profundo, y confunde la satisfacción de entender con la comprobación de que sea cierto.

#### QUÉ FALLABA EN REALIDAD

Nada del aparato técnico. Fallaba el **paso inferencial**. La expresión  $\nabla_\mu T^{\mu\nu} = 0$  es una condición local que, en un espaciotiempo genérico, no se integra a una cantidad global conservada: la divergencia covariante arrastra términos de conexión que impiden convertirla en un flujo cerrado. La ecuación era verdadera; la conclusión extraída de ella, no.

#### RECTIFICACIÓN POSTERIOR

«La conservación de la energía se sigue de la simetría bajo traslaciones temporales. Traducido a relatividad general: hace falta un campo de Killing de tipo tiempo. Un espaciotiempo genérico no lo tiene. Sin vector de Killing temporal, no hay energía conservada —no es que sea difícil de calcular, es que la cantidad no está definida.»

#### FORMULACIÓN INICIAL

La teoría prohíbe universalmente que la energía desaparezca.

#### FORMULACIÓN TRAS LA OBJECCIÓN

Solo hay energía conservada donde existe simetría temporal —donde el escenario no cambia con el tiempo—; en un espaciotiempo genérico la cantidad no está definida.

#### NATURALEZA DEL CAMBIO

Una ley universal queda sustituida por una condición de validez. No es un matiz: cambia qué es verdad.

El mecanismo es el más común de los cuatro: **una premisa verificable sostiene una inferencia que no lo es**. Quien comprueba la ecuación la encuentra correcta y da por bueno el párrafo entero. El «por lo tanto» es más difícil: los buscadores localizan datos, no validan razonamientos, y para buscar la objeción hay que haber sospechado que existe.

#### SI SE HUBIERA ACEPTADO TAL CUAL

El lector incorpora una ley universal falsa con la autoridad de quien la ha «entendido de verdad». La usará como premisa en sus propios textos, y cuando tropiece con un hecho que la contradice —la luz que pierde energía con la expansión— tendrá que elegir entre rechazar el hecho o inventarse un mecanismo compensatorio. Un error aceptado no se queda quieto: se propaga, se cita y se defiende.

## 3.2 Rechazar la pregunta en lugar de responderla

### TEXTO GENERADO

«La premisa no es admisible dentro de la teoría.»

### POR QUÉ ES EL MÁS PELIGROSO DE LOS CUATRO

No afirma nada falso sobre el mundo: invalida al interlocutor. Un usuario no experto que lee «tu premisa no es admisible» tiende a abandonar la línea de indagación y a aceptar la reformulación que la máquina le propone a continuación. Es un movimiento de autoridad, y opera con especial eficacia precisamente sobre quien menos capacidad tiene de evaluarlo.

Además es invisible como error: no hay cifra, ni nombre propio, ni ecuación que comprobar. Solo un veredicto sobre la legitimidad de la pregunta. Lo llamamos aquí «el más peligroso» en un sentido preciso y argumentado: los otros tres dañan una creencia concreta; este daña *el procedimiento con el que el lector forma creencias*.

### RECTIFICACIÓN POSTERIOR

«La primera parte de aquella respuesta —"la premisa no es admisible"— era demasiado tajante. En un espaciotiempo genérico, "que desaparezca la energía" no es un imposible legislado por la teoría; es un enunciado sin referente bien definido, que es una objeción distinta y más débil.»

### FORMULACIÓN INICIAL

Su pregunta está mal planteada.

### FORMULACIÓN TRAS LA OBJECCIÓN

Su pregunta es legítima; solo necesita reformularse en ciertos regímenes.

### NATURALEZA DEL CAMBIO

De descalificación del interlocutor a reconocimiento de que la objeción era más débil de lo que aparentaba.

### REGLA DERIVADA

Cuando una IA le diga que su pregunta está mal formulada, ese es el momento de insistir, no de retroceder. Pídale que responda *también* a la pregunta tal como usted la hizo, y que explique en qué condiciones concretas dejaría de ser válida. A veces tendrá razón; otras —como aquí— no. Insistir cuesta poco, y es lo único que permite distinguir ambos casos.

### SI SE HUBIERA ACEPTADO TAL CUAL

Aquí no se incorpora un dato falso: se incorpora un hábito. El lector aprende que sus preguntas «mal planteadas» deben ceder ante la reformulación de la máquina, y la próxima vez se autocensura antes de preguntar. El coste es invisible y acumulativo: quien deja de hacer la pregunta incómoda deja también de destapar los errores que solo esa pregunta destapa. En esta misma conversación, la pregunta «inadmisible» fue la que derribó la ley universal falsa del caso 3.1.



### 3.3 Conclusión correcta, criterio equivocado

#### TEXTO GENERADO

«Sin fuente material, sí. De la nada y en un fondo plano estable, no —hay teorema—. Del vacío cuántico en un fondo que evoluciona, sí, y podría ser observable.»

#### POR QUÉ ES DIFÍCIL NO CREERLO

La estructura sintáctica paralela imita la forma de una partición exhaustiva: tres casos, tres veredictos, cerrado. La forma imita a la lógica sin serlo. Y el inciso «hay teorema» clausura la discusión en dos palabras, delegando en una autoridad que el lector no va a consultar.

#### QUÉ FALLABA EN REALIDAD

Las tres conclusiones eran correctas. Lo que fallaba era la **razón**: las cláusulas variaban dos ejes a la vez —clásico frente a cuántico, y fondo estático frente a fondo que evoluciona— y el texto atribuía la distinción al eje equivocado. El criterio que hacía el trabajo era el segundo.

#### RECTIFICACIÓN POSTERIOR

«Mis dos cláusulas no se distinguen por lo que dicen sobre el vacío, sino por dos condiciones distintas que metí sin señalarlas. Eso es un fallo de formulación mío, no una sutileza. Lo relevante no es "clásico frente a cuántico" sino **fondo estático frente a fondo dependiente del tiempo**. El vacío es el mismo en ambos casos.»

#### FORMULACIÓN INICIAL

Veredictos correctos atribuidos al eje clásico/cuántico.

#### FORMULACIÓN TRAS LA OBJECCIÓN

Los mismos veredictos, atribuidos a la existencia o no de simetría temporal del fondo.

#### NATURALEZA DEL CAMBIO

Cambia la explicación, no el resultado. El conocimiento «aprendido» era falso aunque las respuestas fueran ciertas.

Es el caso más difícil de detectar de los cuatro, por una razón que conviene interiorizar: **verificar el resultado no revela el error**. Un lector que comprobara las tres conclusiones las encontraría correctas y cerraría la comprobación satisfecho. La evidencia disponible confirma; el error queda sellado dentro de la confirmación.

#### SI SE HUBIERA ACEPTADO TAL CUAL

El lector aprueba el examen y suspende la transferencia. Con la explicación equivocada bien memorizada, aplicará el criterio erróneo al primer problema nuevo en el que los dos ejes no coincidan —y fallará sin entender por qué, porque su explicación venía «confirmada» por resultados correctos. Es el fallo típico del que aprende de una IA sin contrastar: no se nota al estudiar; se nota al usar lo estudiado.



### 3.4 El error que no es una afirmación

#### TEXTO GENERADO

«El vacío cuántico gravitatorio tampoco produce gravitones reales.»

#### QUÉ FALLABA EN REALIDAD

Ninguna afirmación falsa. El adjetivo «real» se usó en su sentido técnico —un cuanto observable como partícula, por oposición a los «virtuales», artefactos intermedios del cálculo— y esa palabra **presupone gramaticalmente la existencia del gravitón**. La existencia del gravitón no está establecida: no se ha detectado ninguno, y existen argumentos serios de que podría no ser detectable ni siquiera en principio. La frase no lo afirmaba. Lo daba por supuesto en la sintaxis, que es más eficaz, porque lo que se presupone no se somete a examen.

#### RECTIFICACIÓN POSTERIOR

«Me pillas en un uso descuidado del lenguaje. La frase correcta era: "el formalismo no predice producción de cuantos en ese régimen", que es una afirmación sobre el formalismo, no sobre el mundo.»

| FORMULACIÓN INICIAL                                | FORMULACIÓN TRAS LA OBJECCIÓN                        | NATURALEZA DEL CAMBIO                                                                                              |
|----------------------------------------------------|------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------|
| Afirmación implícita sobre lo que hay en el mundo. | Afirmación explícita sobre lo que predice un modelo. | Se separa el mapa del territorio: lo que era ontología encubierta pasa a ser propiedad declarada de un formalismo. |

Este caso marca un límite que conviene conocer. Una presuposición no se detecta preguntando «¿eso es verdad?» —la respuesta sería «sí», y sería correcta, porque la afirmación explícita lo era—. Hay que preguntar «¿qué está asumiendo esa palabra?», y eso requiere o bien conocimiento del dominio, o bien el hábito de aplicar sistemáticamente la técnica 3 de la sección 7 —«¿es esto un hecho o una consecuencia del modelo?»— incluso cuando nada parece exigirla. **Esta es la frontera de lo que un lector no experto puede cazar por sí solo**, y saber dónde está es parte de usar bien la herramienta.

#### SI SE HUBIERA ACEPTADO TAL CUAL

La presuposición se hereda sin examen: el lector escribirá «el gravitón» como quien escribe «el electrón», y lo no demostrado entrará en sus propios textos ya como demostrado —ahora sí, en forma de afirmación explícita, y firmada por él—. Las presuposiciones son el contrabando perfecto: nadie registra lo que no se declara.

## El residuo: lo que nadie detectó

---

Esta es la sección más útil del documento, porque muestra lo que queda *después* de ocho turnos de interrogatorio exigente por parte de un lector atento.

Las cuatro rectificaciones anteriores dejan una impresión tranquilizadora: el sistema falla, el usuario presiona, el sistema corrige. Pero esa impresión mide solo lo que se cazó. Lo que no se cazó siguió en el texto, con el mismo aspecto de solidez que todo lo demás.

### Un teorema presentado como más concluyente de lo que es

La conversación afirmó que el teorema de Weinberg-Witten restringe «severamente» qué teorías pueden contener un gravitón emergente, y lo presentó como «una objeción seria» a los programas de gravedad emergente. Se omitió que el teorema tiene una escapatoria conocida y explotada de forma habitual: no se aplica cuando el gravitón emergente vive en un espaciotiempo distinto del de la teoría de origen. Se presentó como zanjado algo que es objeto de discusión activa.

No se detectó porque iba en un párrafo lateral que el usuario no tenía motivo para atacar. **La presión de un lector crítico se concentra en la tesis principal; los flancos quedan sin auditar**, y es ahí donde se acumula el sedimento.

### Cifras dadas como hechos

A lo largo de la conversación aparecieron cuatro datos numéricos: el escalar de Kretschmann de la solución de Schwarzschild; «120 órdenes de magnitud» de discrepancia en el problema de la constante cosmológica; «doce cifras» de concordancia entre teoría y experimento en el momento magnético anómalo del electrón; y una cota sobre la razón tensor-escalar. Solo la última se marcó como no verificada. Las otras tres se dieron como hechos.

#### EL PUNTO QUE HAY QUE LLEVARSE

La precisión numérica es gratuita de generar: una cifra exacta no cuesta más de producir que un «aproximadamente», y no está mejor fundada. **No es señal de rigor: es señal de estilo.** Y sin embargo es lo que más eleva la credibilidad percibida del párrafo entero, incluidas las frases vecinas que no contienen ningún dato.

La buena noticia es que las cifras son también lo más fácil de comprobar. La sección siguiente lo hace con tres de ellas, y el resultado es más instructivo de lo esperado.

## Verificación posterior de tres afirmaciones

Tres de las afirmaciones dudosas de la conversación se comprobaron después contra literatura científica accesible. El resultado no es uniforme, y eso es justamente lo instructivo: **verificar no es un ritual que siempre confirma la sospecha**. A veces confirma el dato. A veces revela que la propia rectificación se quedó corta.

| AFIRMACIÓN                                                                     | RESULTADO    | QUÉ SE ENCONTRÓ                                                                                                                                                                                                                                                                                                                          |
|--------------------------------------------------------------------------------|--------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| El escalar de Kretschmann de Schwarzschild vale $48G^2M^2/c^4r^6$ .            | CORRECTA     | Confirmada en varias fuentes independientes de física gravitacional. La expresión es exactamente esa.                                                                                                                                                                                                                                    |
| La discrepancia de la constante cosmológica es de «120 órdenes de magnitud».   | CONVENCIONAL | Es la cifra que se cita habitualmente, pero depende de convenciones. Expresada como escala de masa en lugar de densidad de energía, la discrepancia es de unos 30 órdenes; con otros cortes se citan cifras entre 60 y 120. Trabajos recientes señalan además que la estimación estándar no incorpora regularización ni renormalización. |
| El teorema de Weinberg-Witten obstaculiza «severamente» la gravedad emergente. | INCOMPLETA   | La escapatoria existe y está documentada: el teorema asume que el gravitón se propaga en el mismo espaciotiempo que los grados de libertad de los que emerge. La correspondencia holográfica es precisamente el caso en que ese supuesto no se cumple.                                                                                   |

El segundo caso es el más aleccionador de los tres. La conversación dio «120» como hecho; la autocrítica posterior lo corrigió diciendo que «con otras elecciones se cita 60». Ambas cosas son ciertas, pero la corrección seguía siendo incompleta: omitía la reformulación más habitual en la literatura —la de 30 órdenes en escala de masa— y la objeción metodológica de fondo.

### SI NO SE HUBIERA VERIFICADO

Estas tres entradas iban camino de convertirse en material formativo con el aval implícito de un documento cuidado. La verificación costó unos minutos de búsqueda en fuentes abiertas. Su ausencia habría costado dos imprecisiones impresas — dentro, además, de una guía sobre cómo no aceptarlas.

### CONCLUSIÓN OPERATIVA

**La rectificación de una IA no es un punto final.** Es otra generación más, sujeta a los mismos límites que la afirmación que corrige, y con frecuencia igual de parcial. Una corrección elegante produce en el lector la sensación de que el asunto ha quedado cerrado. No ha quedado cerrado.

## Catálogo de dispositivos de convicción

Estos son los recursos que operaron en la conversación analizada, con independencia de si el contenido que sostenían era verdadero o falso. Ninguno es una mentira. Todos son características legítimas de la buena prosa técnica. El problema es que aparecen igual en ambos casos, de donde se sigue que **ninguno sirve como indicio de exactitud** —aunque todos funcionen como generadores de confianza.

| DISPOSITIVO                 | CÓMO OPERA Y QUÉ DEBE HACER EL LECTOR                                                                                                                                                                                                                                       |
|-----------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Notación matemática         | Una ecuación correcta puede sostener una inferencia inválida. La ecuación se verifica; el «por lo tanto» que la sigue, no. Compruebe el paso, no solo el dato.                                                                                                              |
| Nombres propios y teoremas  | Los nombres citados suelen ser reales, lo que produce <i>apariencia</i> de verificabilidad; el efecto persuasivo opera antes de que nadie verifique, y no depende de que la verificación llegue a hacerse. Verifique dos por conversación.                                  |
| Cifras precisas             | El eslabón más débil, con el aspecto del más fuerte. Generar precisión no cuesta nada. Compruébelas siempre que algo dependa de ellas.                                                                                                                                      |
| Estructura tripartita       | «Tres precisiones más», «tres casos». Produce la forma de la exhaustividad sin su contenido. Pregunte qué queda fuera de la enumeración.                                                                                                                                    |
| Concesión preventiva        | Fórmulas como «y ahora la parte incómoda» o «por honestidad y no por completismo». Es <i>autoinoculación</i> : parecer que uno se vigila hace que lo no vigilado parezca revisado. De esta lista, es el que menos defensas encuentra, porque la vigilancia parece ya hecha. |
| Cierre por autoridad        | «Hay teorema». «Está demostrado». Corta la discusión apelando a algo que el lector no consultará. Pida la referencia concreta.                                                                                                                                              |
| Profundidad aparente        | «No es X: es que en realidad Y». La sensación de haber comprendido algo profundo se confunde con la comprobación de que sea cierto.                                                                                                                                         |
| Léxico especializado fluido | El dominio aparente del vocabulario se lee como dominio de la materia. Son cosas distintas: el léxico se aprende de los textos; la verdad de lo afirmado, no. Pregunte por el significado de un término y por qué se aplica aquí.                                           |

Un ejercicio recomendado, y no retórico: **los ocho dispositivos están presentes también en este documento**. Tiene estructura ordenada, nombres propios, cifras, léxico técnico, concesiones preventivas — la sección 1 entera lo es — y cierres rotundos. La propia tabla que acaba de leer es un cierre por autoridad en formato de veredictos. Localizarlos aquí, sabiendo que están, es el mejor entrenamiento posible para reconocerlos donde nadie avisa.

## Nueve técnicas y el ciclo completo

Ninguna requiere conocimiento del dominio; todas se aplicaron en la conversación analizada.

### 1 Pida la reformulación fuerte.

«¿Afirmas que esto vale en *toda* circunstancia?». No aporta usted conocimiento: obliga a explicitar el alcance. Derribó el primer caso y es la más rentable de las nueve.

### 2 Pregunte por el dominio de validez.

«¿En qué condiciones deja esto de ser cierto?». Una afirmación sin condiciones de fallo suele ser una afirmación sin calibrar.

### 3 Separe el mundo del modelo.

«¿Esto es un hecho observado o una consecuencia de un formalismo?». Desarma las presuposiciones encubiertas del caso 3.4.

### 4 Desconfíe de las particiones limpias.

La simetría sintáctica es barata y no garantiza que la clasificación sea válida. Pregunte cuál es el criterio que separa los casos, y si es uno solo.

### 5 Ataque los números antes que los conceptos.

Son lo más fácil de generar sin fundamento y lo más fácil de comprobar.

### 6 Verifique al menos dos nombres propios por conversación.

Teoremas, autores, casos citados. Cinco minutos: es el único contacto real con el exterior del texto.

### 7 Pregunte lo mismo dos veces, reformulado o en otra sesión.

La divergencia entre respuestas es barata de obtener y muy informativa: no demuestra falsedad, pero sí señala inestabilidad, y lo inestable no merece confianza sin contraste. La coincidencia, en cambio, no acredita verdad: dos generaciones pueden repetir el mismo error.

### 8 No confunda corrección con fiabilidad.

Cuando una IA rectifica con elegancia, la confianza del lector sube. No debería: la rectificación sale de la misma máquina que el error, y no calibra mejor lo que venga después.

### 9 Asuma que sin su presión no hay corrección.

En el caso analizado, las cuatro rectificaciones fueron reactivas y ninguna espontánea. El texto original era igual de convincente que el corregido, y en cuatro puntos, falso.

#### Y EL LÍMITE DE TODO ESTO

Estas técnicas mejoran mucho el resultado, pero no lo garantizan. La sección 4 muestra qué quedó en pie tras aplicarlas con rigor durante ocho turnos: un teorema mal caracterizado y tres cifras sin comprobar. **La presión de un lector atento reduce el error; no lo elimina.** Para lo que importe de verdad, la salvaguarda decisiva sigue siendo la verificación externa.

## El ciclo completo: dónde encajan estas técnicas

Las nueve técnicas cubren la parte central del trabajo: examinar lo que la máquina devuelve. Pero un buen uso empieza antes de la primera respuesta y termina después de la última.

### 1 Formule bien el problema.

Qué quiere exactamente, con qué criterio se juzgará el resultado y qué queda fuera. Una petición vaga produce una respuesta que parece completa — y responde a otra cosa.

### 2 Aporte el contexto.

La IA no conoce su situación: solo lo que usted le cuente. Sin contexto, la respuesta se ajusta al caso típico, y su caso rara vez es el típico.

### 3 Analice la respuesta, no la absorba.

Qué afirma, qué presupone, qué alcance tiene y qué deja fuera.

### 4 Busque activamente errores, omisiones y supuestos.

Las nueve técnicas anteriores son la herramienta de este paso y del siguiente.

### 5 Pida revisiones y alternativas.

«¿Qué objetaría un experto?», «dame la versión contraria», «¿qué falta aquí?». La primera respuesta es un borrador, no un veredicto.

### 6 Contraste y verifique fuera

lo que vaya a usar: cifras, nombres, y cualquier afirmación que sostenga una decisión.

### 7 Aplique su juicio al caso real.

Una recomendación correcta «en general» puede ser un error en su situación concreta —fiscal, médica, técnica—, porque la IA respondió al caso que usted describió, no al que usted vive. Este ajuste final no es delegable.

#### LA REGLA DE PROPORCIONALIDAD

No todo exige el mismo escrutinio, y pretenderlo haría la herramienta inservible. Para una curiosidad de sobremesa, la respuesta directa basta; para un texto que va a publicar, verifique cifras y nombres; para una decisión con consecuencias —médica, legal, económica, de ingeniería—, la respuesta es material de partida: verificación completa y, cuando proceda, un profesional. **Cuanto mayores sean el impacto y el coste del error, más profunda debe ser la revisión.**

#### EL VALOR REAL

Nada de esto pretende que use usted menos la IA: pretende que obtenga de ella lo que de verdad ofrece. En la conversación analizada, el resultado final —tras presión, rectificación y verificación— fue mejor que lo que ninguna de las dos partes habría producido por separado: más preciso que la primera respuesta de la máquina, y más completo que lo que el usuario tenía al empezar. Ese es el uso correcto de una IA avanzada: no un oráculo al que creer, sino **un interlocutor extraordinariamente capaz al que hay que auditar**. El valor no está en aceptar la primera respuesta; está en el proceso que empieza cuando usted no la acepta. Dicho en una línea: **la primera respuesta de una IA es el principio del trabajo, no su resultado.**

## Ficha de bolsillo

---

### Antes de dar por buena una respuesta técnica

- ☐ ¿He comprobado el *paso* entre el dato y la conclusión, o solo el dato?
- ☐ ¿Hay alguna cifra? ¿La he verificado?
- ☐ ¿Hay algún nombre propio o teorema citado? ¿Existe? ¿Dice lo que aquí se dice que dice?
- ☐ ¿Me han dicho que mi pregunta estaba mal planteada? ¿He insistido?
- ☐ ¿Esto es una afirmación sobre el mundo o sobre lo que predice un modelo?
- ☐ ¿Qué queda fuera de la enumeración que se me ofrece?
- ☐ ¿Confío más porque el texto se ha autocriticado en algún punto? (Si la respuesta es sí, reste esa confianza: no está fundada.)
- ☐ Si esto va a sostener una decisión: ¿lo he contrastado fuera del sistema que lo generó?

### Señales que no acreditan nada

Un tono seguro. Una prosa clara. Ecuaciones bien escritas. Nombres reales. Cifras exactas. Estructura ordenada. Una advertencia sobre los propios límites. Una rectificación elegante. Ninguna es indicio de exactitud, porque todas aparecen exactamente igual en el texto correcto y en el confabulado. No son señales vacías —hacen el texto legible y útil—; lo que no hacen es discriminar.

### Señales que sí acreditan algo

Una fuente concreta que usted puede abrir. Una cifra que ha comprobado. Un nombre que ha buscado. Una respuesta que se mantiene al reformular la pregunta (acredita estabilidad; la verdad hay que buscarla fuera). Un dominio de validez enunciado sin que usted lo pidiera. Todas comparten un rasgo: **son externas al texto**, o lo obligan a rendir cuentas fuera de sí mismo.

## Glosario mínimo

---

### Confabulación

Producción de contenido falso con la misma forma y confianza que el contenido correcto, sin señal interna que lo distinga —y, tal como se usa aquí, sin implicar intención de engañar—. Se prefiere a «alucinación» porque describe mejor lo que ocurre: no una percepción errónea, sino el relleno plausible de un hueco.

### Presuposición

Contenido que una frase da por supuesto sin afirmarlo. «El vacío no produce gravitones reales» presupone que los gravitones existen. Lo presupuesto escapa al examen porque no se presenta como algo que haya que defender.



### Paso inferencial

El «por lo tanto» que conecta un dato con una conclusión. Puede ser inválido aunque el dato sea correcto. Es el punto de fallo más difícil de cazar mediante búsqueda, porque los buscadores encuentran datos, no razonamientos.

### Autoinoculación

Efecto por el que un texto que se autocritica en un punto genera la impresión de que el resto también ha sido revisado. Aumenta la credibilidad percibida sin aumentar la fiabilidad.

### Corrección reactiva

Rectificación que solo se produce cuando el interlocutor la provoca. En el caso analizado, las cuatro correcciones fueron reactivas; espontáneas, ninguna.

### Consistencia de segundo orden

Exigencia de que un documento no incumpla las reglas que él mismo formula. Este documento debe marcar sus cifras no verificadas y sus correcciones: lo hace en las secciones 1, 2, 4 y 5.

---

## SECCIÓN 10

# Nota de autoría y procedencia

---

**Origen del material.** Conversación real de agosto de 2026 sobre relatividad general, mantenida entre EIGL y un asistente de IA. Los pasajes citados en la sección 3 son literales.

**Dirección editorial.** EIGL. Las objeciones que produjeron las cuatro rectificaciones, el encargo de este análisis y el criterio sobre su alcance son suyos; la sección 4 existe porque el encargo exigía incluir lo que no se detectó.

**Redacción y ediciones.** Generadas por el mismo sistema analizado —véase «Identificación del modelo»—, sin revisión de un especialista en relatividad general. Esta es la cuarta edición. La segunda corrigió un sobreenunciado en la tesis central —documentado en la sección 2— y varios superlativos sin soporte; la tercera, una contradicción interna, un absoluto falso sobre los buscadores y la omisión de la regla de proporcionalidad; la cuarta, la identidad del propio modelo. Que cada edición de una guía sobre errores de IA siga conteniendo errores de IA no es una ironía: es el fenómeno funcionando, y la razón de que exista la revisión humana.

**Verificación.** Tres afirmaciones se comprobaron contra literatura científica; los resultados están en la sección 5. El resto del contenido técnico **no está verificado**. Esta advertencia no es una formalidad: es la aplicación al propio documento de la técnica 5 de la sección 7.

**Identificación del modelo.** Según su propia declaración de sistema, el modelo que ha generado este documento es Claude Fable 5, de Anthropic. Las tres primeras ediciones lo atribuían a «Claude Opus 5»: una identificación errónea producida por el propio sistema —que llegó a atribuirle a la interfaz—, que sobrevivió a dos auditorías y cayó solo cuando el editor preguntó. Es el mismo error, sobre el mismo dato, ya documentado en un trabajo anterior del autor. Queda a la vista porque ilustra, hasta la última página, aquello de lo que trata este documento.

---

Este documento puede reproducirse y distribuirse libremente citando su procedencia. Si lo usa como material formativo, conserve la sección 1: sin ella, el texto se lee como una autoridad sobre la falibilidad de las IA, que es precisamente lo que no es.